

**Высшая школа экономики**

**Факультет компьютерных наук**

**Направление «Прикладная математика и информатика»**

**Курсовая работа**

**Использование суффиксных структур в задачах  
обработки и анализа текстов**

Студент: А. А. Урусов  
Преподаватель: Е. Л. Черняк

**Москва, 2016**

# 1. Введение

Одной из самых широко встречающихся на данный момент задач в анализе текстов является задача кластеризации, то есть разбиение некоторого множества документов на такие группы, что документы из одной группы так или иначе похожи друг на друга, в то время как документы из разных групп совершенно разные.

Одним из примеров такой задачи является кластеризация новостных потоков, где в качестве текстов выступают новостные статьи за какой-то период времени. Это позволяет выделить из большого количества документов основные сюжеты, что значительно облегчает поиск актуальной информации. Кроме того, изучив различные документы одного кластера, мы можем проанализировать статьи об одном и том же событии из разных источников и выделить общие и различающиеся моменты, что позволяет сделать получаемую информацию более достоверной.

Другой пример, описанный также в 16й главе из [1], - информационный поиск. Здесь широко применяется *кластерная гипотеза*, которая гласит, что документы из одного кластера ведут себя примерно одинаково при одном и том же поисковом запросе. Это позволяет лучше подбирать документы для каждого запроса, поскольку если мы уже определили релевантность некоторой статьи запросу, то в соответствии с кластерной гипотезой другие документы из того же кластера тоже релевантны этому запросу.

Кроме того, кластеризация хорошо помогает, если пользователь ищет не какую-то конкретную информацию, а просто хочет почитать что-нибудь, что было бы ему интересно. В этом случае поиск интересных статей можно осуществить следующим образом. Изначально все множество статей кластеризуется на небольшое количество кластеров, и для каждого кластера определяется общая тематика статей в этом кластере. Далее пользователь выбирает одну или несколько (но не все) темы, которые ему интересны. Полученные документы снова кластеризуются. Это повторяется до тех пор, пока множество документов не станет достаточно маленьким. В таком случае пользователю просто предоставляется список полученных статей, которые с достаточно высокой вероятностью будут интересны пользователю. В частности, похожая идея реализована в сервисе [dmoz.org](http://dmoz.org).

## 2. Формальная постановка задачи кластеризации

Самая общая постановка задачи кластеризации документов, согласно [1], следующая. Дается некоторый набор документов  $D = \{D_1, \dots, D_n\}$ , и желаемое количество кластеров  $K$ . Требуется найти такое отображение  $\gamma : D \rightarrow \{1, \dots, K\}$ , которое максимизирует некоторую целевую функцию, показывающую, насколько кластеризация хорошая.

Большинство алгоритмов кластеризации можно разделить на 2 основных типа. Пер-

вый из них, *объектно-признаковый*, заключается в том, что документы тем или иным образом представляются в многомерном векторном пространстве, где каждая координата является *признаком*, и значение этой координаты у каждого документа говорит о том, насколько этот признак выражен в данном документе. Плюсом этого способа представления является достаточно простая математическая интерпретация множества документов. Однако, задача по выбору подходящего набора признаков и подбора значений координат часто бывает очень сложной, и поэтому вместо этого используются *аффинные* алгоритмы кластеризации. Их суть заключается в том, что задача решается на основе матрицы похожести, выраженной действительным числом для каждой пары документов.

Рассмотрим теперь некоторые аффинные алгоритмы, использованные для кластеризации, а именно, следующие:

- Модификация k-means
- K-medoids
- Spectral clustering

Отметим, что в первых 2х алгоритмах требуется не похожесть, а, наоборот, расстояние между документами, то есть некоторая величина, которая тем больше, чем меньше документы похожи. В качестве такой величины удобно использовать значение  $\frac{1}{similarity}$ .

### 3. Аффинные алгоритмы кластеризации

#### 1. Модификация k-means

Классический k-means описан, например, в [3] и заключается в следующем. Пусть есть сколько-то точек в некотором линейном пространстве. Сначала выбираем случайно k точек - центроиды наших кластеров. Далее итеративно выполняем следующее:

- Пересчитываем кластеры, а именно, для каждой точки множества находим ближайший центроид.
- Пересчитываем центроиды, то есть для каждого из полученных кластеров находим новый центроид как центр масс кластера.

Однако, проблема заключается в том, что у нас нет самих координат точек, а только расстояния между ними (расстояния считаются как  $\frac{1}{similarity}$ ). В связи с этим модифицируем алгоритм следующим образом: будем выбирать изначальные центроиды как

элементы нашего множества, а при пересчете будем выбирать тот элемент множества, от которого сумма расстояний до точек кластера минимальна. Таким образом, нам не требуется знать координаты точек, а только попарные расстояния между ними.

## 2. K-medoids

Идея алгоритма похожа на k-means, но отличается способом пересчета центроидов. Изначально мы инициализируем кластеризацию, выбрав k случайных центроидов и отнеся каждый из остальных элементов в кластер к ближайшему центроиду. Далее, на каждой итерации для каждого документа пробуем поменять его с центром его кластера. Для полученной конфигурации пересчитываем кластеры (т.е. для каждого документа выбираем ближайший центр) и вычисляем некоторую величину, которая показывает, насколько хороша полученная кластеризация. В данном случае удобно использовать сумму расстояний от каждого документа до его центра. Таким образом, чем меньше эта величина, тем лучше кластеризация. Итак, для каждой из таких замен мы посчитали, насколько улучшится (и улучшится ли вообще) кластеризация. Теперь просто выберем ту, которая дает самое большое улучшение, и применим. Количество итераций в этом алгоритме, в отличие от k-means, не выбирается фиксированным, а алгоритм выполняется до тех пор, пока у нас получается найти улучшающую замену. При выбранных ограничениях (8000 элементов) на практике требуется всего несколько десятков итераций, поэтому алгоритм достаточно быстро завершает работу.

Более подробно этот алгоритм описан в [4] и [5].

## 3. Spectral clustering

Этот алгоритм был выбран как самый подходящий из модуля scikit-learn для python. Его суть состоит в нахождении координат точек в k-мерном пространстве по матрице похожести, и после этого применяется k-means к полученным точкам. Для дальнейшего изучения см. [6].


## 4. Нахождение попарной похожести текстов

### 1. Понятие об аннотированном суффиксном дереве

Ранее аннотированные суффиксные деревья уже описывались, например, в [2]. Далее повторим эту идею и применим ее для поставленной задачи.

Чтобы определить аннотированное суффиксное дерево, определим сначала более общее понятие *бора*. Итак, *бор* - это структура данных для хранения набора строк, представляющая собой корневой дерево, каждому ребру которого соответствует некоторый символ. При этом некоторые вершины помечены как *терминальные*. Каждой вершине ставится в соответствие строка как последовательность символов, написанных на ребрах между корнем и этой вершиной. Говорят, что бор *принимает* строку  $s$ , если есть такая терминальная вершина, которой соответствует строка  $s$ .


Приведем пример. Пусть у нас есть набор строк, например,  $A = \{\text{"гол"}, \text{"горн"}, \text{"гик"}, \text{"пик"}\}$ . Для него бор будет выглядеть следующим образом:



Здесь для удобства все вершины пронумерованы, а терминальные отмечены красным цветом.

Тогда, например, вершине 10 соответствует строка "горн", поскольку последовательность ребер от корня до нее выглядит как  $0 \rightarrow 1, 1 \rightarrow 3, 3 \rightarrow 6, 6 \rightarrow 10$ , и ей соответствует последовательность символов "горн".

Заметим, что в текущем определении есть некоторая неоднозначность. Действительно, например, следующее дерево также удовлетворяет всем условиям:




Чтобы избежать этого, потребуем дополнительно, чтобы для каждой вершины  $v$  и символа  $s$  было не более одного ребра из  $v$  в какого-нибудь из ее потомков, соответствующего символу  $s$ . Кроме того, потребуем, чтобы все листья были терминальными вершинами, то есть соответствовали какой-нибудь строке из множества (иначе дерево может быть сколь угодно большим). Тогда для любого множества строк бор определяется однозначно. Действительно, пусть есть 2 различных бора для одного и того же множества строк. Найдем ребро, которое есть в одном, но нету во втором, причем если таких несколько, то выберем то, которое ближе всех к корню. Пусть это ребро  $v \rightarrow to$ , ему соответствует символ  $s$ , а вершине  $v$  - строка  $s$ . Поскольку каждый лист - терминальная вершина, какой-то потомок  $to$  - терминальная вершина, значит, в множестве строк есть какая-то строка  $S$  с префиксом  $s + s$ . С другой стороны, если мы пойдем от корня по строке  $s$  во втором дереве (то есть сначала пойдем по ребру, которому соответствует символ  $s_0$ , потом -  $s_1$ , и так далее), то мы, очевидно, придем в ту же вершину  $v$ . Однако, мы не сможем пойти дальше по символу  $s$  по предположению, значит, второй бор не может принимать строку с префиксом  $s + s$ . Таким образом, мы пришли к противоречию, и тем самым доказали, что бор по множеству строк определяется однозначно. Кроме того, доказательство показывает способ построения этого бора. Пусть изначально бор пустой, то есть состоит из 1й вершины - корня. Будем последовательно добавлять в него строки следующим образом: будем идти по имеющемуся дереву в соответствии с очередной строкой  $s$ , и если в какой-то момент не находим нужного ребра, то просто создаем новое ребро, ведущее из текущей вершины в новую и соответствующее нужному нам символу. В конце помечаем вершину, в которой оказались, терминальной. Очевидно, этот алгоритм не может добавить 2 ребра с одним и тем же символом из одной вершины, потому что

мы создаем ребро, только если его еще нет, и каждый лист будет терминальным, потому что каждая вершина соответствует некоторому префиксу какой-то из строк множества, значит, у каждой вершины есть терминальный потомок.


Пусть теперь у нас есть некоторый текст, который мы будем рассматривать как некоторый набор слов. *Суффиксным деревом* для этого текста назовем бор, который принимает суффиксы всех слов и только их.

Снова приведем пример. Пусть есть, например, текст, состоящий из 2х слов "голод" и "холод". Тогда суффиксное дерево должно принимать все суффиксы этих двух слов, то есть строки "голод", "олод", "лод", "од", "д", "холод". Построим бор на этих строках по выше приведенному алгоритму:



Теперь введем понятие *аннотированного суффиксного дерева*. Аннотированное суффиксное дерево для набора строк - это суффиксное дерево, в котором для каждой вершины дополнительно хранится целое число (частота) - количество строк из набора, префиксом которых является строка, соответствующая этой вершине. Заметим, что это не всегда совпадает с количеством терминальных вершин в поддереве, поскольку в наборе каждая из строк может встречаться несколько раз.

Например, для суффиксного дерева, которое было построено ранее, аннотированное суффиксное дерево будет выглядеть следующим образом:




Так, в этом примере суффиксы "олод", "лод", "од", "д" учитываются по 2 раза. Отметим, алгоритм, приведенный выше для построения суффиксного дерева легко модифицировать для подсчета частот. Действительно, при добавлении очередного суффикса в дерево значения частот в вершинах пути от корня к вершине, отвечающей за этот суффикс, увеличиваются на 1, а в остальных - не изменяются. Поэтому можно просто добавлять 1 к частоте каждой вершины, которую проходим. У только что созданных вершин это значение должно быть равным 0, поскольку мы еще ни разу не проходили эту вершину.

## 2. Нахождение величины похожести текстов на основе суффиксных деревьев


Пусть есть 2 текста  $A, B$ . Построим по ним аннотированные суффиксные деревья  $S_A, S_B$ . Далее найдем для этих суффиксных деревьев *общее поддерево*  $S$ , то есть такое подмножество вершин, которые есть в обоих деревьях. При этом в качестве частот в  $S$  будем использовать  $f(a, b)$ , где  $a, b$  - частоты вершины в  $S_A, S_B$ , а  $f$  - некоторая функция. Теперь остается оценить это дерево. В качестве оценки используем величину  $\sum_v \frac{frequency(v)}{frequency(p(v))}$ , где  $frequency(v)$  - частота вершины, а  $p(v)$  - предок вершины  $v$ . Таким образом, мы суммируем по всем вершинам их условную вероятность появления в тексте, то есть вероятность перехода в вершину  $v$  при условии, что мы уже дошли до  $p(v)$ .

Рассмотрим, например, 2 текста  $A = \{\text{"голод"}, \text{"холод"}\}$ ,  $B = \{\text{"солود"}, \text{"вол"}\}$ . Для  $A$  мы уже строили дерево выше, для  $B$  оно выглядит следующим образом:





Тогда общее поддерево имеет следующий вид:



Пусть  $f(a, b) = \frac{a+b}{2}$ . Тогда оценка похожести равна:

$$\begin{aligned} & \frac{f(3, 4)}{f(8, 10)} + \frac{f(1, 2)}{f(8, 10)} + \frac{f(2, 2)}{f(8, 10)} + \frac{f(1, 2)}{f(3, 4)} + \frac{f(2, 2)}{f(3, 4)} + \frac{f(1, 2)}{f(2, 2)} + \frac{f(1, 2)}{f(2, 2)} + \frac{f(1, 2)}{f(1, 2)} + \frac{f(1, 2)}{f(1, 2)} = \\ & \frac{3+4}{8+10} + \frac{1+2}{8+10} + \frac{2+2}{8+10} + \frac{1+2}{3+4} + \frac{2+2}{3+4} + \frac{1+2}{2+2} + \frac{1+2}{2+2} + \frac{1+2}{1+2} + \frac{1+2}{1+2} = 5.27778 \end{aligned}$$

### 3. Параметризация

Как можно заметить, данный алгоритм нахождения похожести принимает один дополнительный параметр, а именно, функцию  $f(a, b)$ . В данной работе были использованы следующие функции:

- $f(a, b) = \frac{a+b}{2}$
- $f(a, b) = \min(a, b)$
- $f(a, b) = \max(a, b)$
- $f(a, b) = \sqrt{ab}$

## 4. Стандартный способ нахождения похожести

Опишем кроме этого способа и стандартный, широко используемый при анализе текстов.

Для того, чтобы найти матрицу похожести, в данном случае сначала представим наше множество документов в объектно-признаковом виде. Для этого выберем в качестве признаков слова, а в качестве координаты будем использовать значение, равное  $\frac{tf}{df}$ , где  $tf$  (term-frequency) - количество экземпляров слова в тексте, а  $df$  (document-frequency) - количество документов из множества, содержащих это слово. Таким образом, чем чаще слово встречается в документе, тем больше эта координата, однако чем более оно распространено в разнообразных документах, тем она меньше.

Далее просто применим к этому представлению cosinesimilarity, то есть положим похожесть двух векторов равной косинусу угла между ними.

## 5. Проведение эксперимента

Чтобы иметь возможность сравнивать различные алгоритмы кластеризации, нужно привести способ оценивания их эффективности. В данной работе для тестирования использовалось подмножество популярной коллекции Reuters-21578, а именно, были выбраны все тексты из нее, которые принадлежат ровно одной из списка категорий {acq, crude, earn, grain, interest, money-fx, ship, trade}. Таким образом, выделялось 8 кластеров.

Для каждого из тестируемых алгоритмов и для каждого способа нахождения попарной похожести из списка выше находится кластеризация, то есть разбиение множества документов на несколько групп, обозначенных метками. Далее, с целью вычисления эффективности решения для каждого из найденных кластеров находится самая часто встречающаяся категория, которая и полагается основной для данного кластера, и затем считается доля ошибок, то есть количество документов, категория которых не совпадает с категорией их кластера, деленное на общее количество документов. Ниже приведены результаты тестов. Исходный код доступен по ссылке <https://github.com/urusant/coursework>.

## 1. k-means

- Для  $f(a, b) = \frac{a+b}{2}$  результат равен 0.523162.
- Для  $f(a, b) = \min(a, b)$  результат равен 0.469608.
- Для  $f(a, b) = \max(a, b)$  результат равен 0.516789.
- Для  $f(a, b) = \sqrt{ab}$  результат равен 0.514338.
- Для стандартного способа результат равен 0.655392.

## 2. k-medoids

- Для  $f(a, b) = \frac{a+b}{2}$  результат равен 0.545833.
- Для  $f(a, b) = \min(a, b)$  результат равен 0.484681.
- Для  $f(a, b) = \max(a, b)$  результат равен 0.575.
- Для  $f(a, b) = \sqrt{ab}$  результат равен 0.546569.
- Для стандартного способа результат равен 0.648284.

## 3. Spectral clustering

- Для  $f(a, b) = \frac{a+b}{2}$  результат равен 0.6867647058823529.
- Для  $f(a, b) = \min(a, b)$  результат равен 0.6938725490196078.
- Для  $f(a, b) = \max(a, b)$  результат равен 0.6843137254901961.
- Для  $f(a, b) = \sqrt{ab}$  результат равен 0.6922794117647059.
- Для стандартного способа результат равен 0.7115196078431373.

## 6. Выводы

На основе проделанного исследования можно сделать несколько выводов.

Во-первых, доля ошибок примерно одинаковая для каждой из четырех функций, которые выбирались как параметры при нахождении похожести текстов. Это не значит, что можно выбирать совершенно любую функцию от двух переменных: все приведенные примеры удовлетворяют условию  $\min(a, b) \leq f(a, b) \leq \max(a, b)$ , что логично.

Однако, можно сделать вывод, что выбор функции не является существенным, и поэтому в большинстве случаев можно использовать какую-нибудь достаточно простую, например, среднее арифметическое.

Во-вторых, результаты говорят, стандартный подход к нахождению похожести значительно более эффективен, однако в Spectral clustering они различаются лишь незначительно, что означает возможность применения этого подхода в реальных задачах с небольшими потерями. Тем не менее, в текущей реализации это не слишком хорошая идея, поскольку генерация таблицы занимает достаточно много времени, соответственно, для использования этого алгоритма его необходимо значительно оптимизировать.

## 7. Список литературы

- [1] Christopher D. Manning, Prabhakar Raghavan and Hinrich Schütze, Introduction to Information Retrieval, Cambridge University Press. 2008 (<http://nlp.stanford.edu/IR-book/>)
- [2] М. Дубов, Е. Черняк, Аннотированные суффиксные деревья: особенности реализации (<https://www.hse.ru/pubs/share/direct/document/103661353>)
- [3] Статья об алгоритме k-means из Wikipedia (<https://ru.wikipedia.org/wiki/K-means>)
- [4] Статья об алгоритме k-medoids из Wikipedia (<https://en.wikipedia.org/wiki/K-medoids>)
- [5] Кластеризация графов и поиск сообществ. Часть 2: k-medoids и модификации (<https://habrahabr.ru/company/dca/blog/264811/>)
- [6] Документация scikit-learn (<http://scikit-learn.org/stable/>)